

# ANÁLISE DE DADOS MULTIVARIADOS I - REGRESSÃO

(AULA 10)

**Novembro e dezembro de 2018**

Reinaldo Soares de Camargo

# Modelos Lineares Generalizados

# Modelos lineares Generalizados

- Modelos lineares generalizados (MLGs) são definidos por uma distribuição de probabilidade para a variável resposta  $Y$  pertencente à família exponencial, um conjunto de variáveis explicativas que podem ser numéricas ou categóricas e uma função de ligação.
- Um dos modelos lineares generalizados mais utilizados na área de saúde é o modelo de regressão logística binária, onde a variável resposta do modelo tem distribuição de Bernoulli (ou Binomial) e a função de ligação é a função logística. Na área de saúde, o referido modelo poderia ser adotado, por exemplo, para estimar a probabilidade do paciente: aderir ao tratamento medicamentoso (adesão=1; não adesão=0); reportar um estado de saúde não bom (não bom=1; bom=0); ter uma determinada doença crônica (ter DC=1; não ter DC=0).
- A função utilizada para ajustar modelos lineares generalizados no R é a função “glm”. Nesta função é necessário especificar as variáveis explicativas e a variável resposta do modelo, a distribuição de probabilidade da variável resposta do modelo (family) e a função de ligação (link) desejada pelo pesquisador. Com a função “glm” é possível obter as estimativas pontuais dos parâmetros do modelo e algumas medidas de qualidade do ajuste (AIC e deviances).
- Após a ajustar o MLG de interesse é necessário utilizar a função “summary” para obter outros resultados do ajuste do modelo além das estimativas pontuais. Entre os resultados obtidos com a função “summary” do RStudio estão: as estimativas pontuais, os erros padrão referentes as estimativas pontuais, os valores observados da estatística de Wald e os p-valores do teste de Wald.

# Modelos Lineares Generalizados

- Na área de saúde, os pesquisadores estão mais interessados em analisar as estimativas das medidas de associação (como, por exemplo, a razão de prevalência ou a razão de chance, em inglês *odds ratio*) ao invés das estimativas pontuais dos parâmetros do modelo. Entretanto, estas medidas de associação não fazem parte do conjunto de resultados fornecidos pela função “summary” do RStudio. O exemplo a seguir mostra como ajustar o modelo de regressão logística binária usando a função “glm”, e como obter as medidas de razão de chance e seus respectivos intervalos de confiança a partir das saídas fornecidas pelo comando “glm”.
  - Os dados se referem a um estudo sobre autoavaliação geral de saúde (1=não boa, 0=boa) de n=30 indivíduos com idade variando de 20 a 95 anos. O objetivo do estudo é estudar a relação entre a autoavaliação de saúde (Y) e as seguintes variáveis explicativas: idade(em anos) e renda familiar per capita (1=Mais de 3 s.m, 0= Até 3 s.m=base).
- `modelo1=glm(saude~idade+renda,family=binomial(link="logit"))`  
`summary(modelo1)`

# Modelos Lineares Generalizados

- estimativas pontuais dos parâmetros e os seus erros padrão, os valores observados da estatística de Wald e os p-valores do teste de Wald, entre outras informações.

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -2.93790    1.74439  -1.684  0.09214 .
idade       0.13296    0.05123   2.595  0.00945 **
renda      -3.17898    1.45863  -2.179  0.02930 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 38.191  on 29  degrees of freedom
Residual deviance: 18.711  on 27  degrees of freedom
AIC: 24.711

Number of Fisher Scoring iterations: 6
```

- Medidas de associação (razões de chance).** Pode-se demonstrar matematicamente que a razão de chance é o exponencial da estimativa pontual.

```
> OR1=exp(modelo1$coefficients);OR1
(Intercept)      idade      renda
0.05297680  1.14220209  0.04162821
```

# Modelos Lineares Generalizados

- estimativas pontuais dos parâmetros e os seus erros padrão, os valores observados da estatística de Wald e os p-valores do teste de Wald, entre outras informações.

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -2.93790    1.74439  -1.684  0.09214 .
idade       0.13296    0.05123   2.595  0.00945 **
renda      -3.17898    1.45863  -2.179  0.02930 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 38.191  on 29  degrees of freedom
Residual deviance: 18.711  on 27  degrees of freedom
AIC: 24.711

Number of Fisher Scoring iterations: 6
```

- Medidas de associação (razões de chance).** Pode-se demonstrar matematicamente que a razão de chance é o exponencial da estimativa pontual.

```
> OR1=exp(modelo1$coefficients);OR1
(Intercept)      idade      renda
0.05297680  1.14220209  0.04162821
```

# Modelos Lineares Generalizados

- Os intervalos de 95% de confiança para os parâmetros do modelo, com base na estatística de Wald.

```
> ICbeta1=confint.default(modelo1, level=0.95); ICbeta1
```

	2.5 %	97.5 %
(Intercept)	-6.35684588	0.4810436
idade	0.03255546	0.2333606
renda	-6.03783801	-0.3201166

- Os intervalos de 95% de confiança para os parâmetros do modelo, com base na estatística de Wald

```
> ICOR1=exp(ICbeta1); ICOR1
```

	2.5 %	97.5 %
(Intercept)	0.001734830	1.6177619
idade	1.033091190	1.2628368
renda	0.002386713	0.7260644

- Razão de chance e intervalo de confiança

```
> round((cbind(OR1, ICOR1)),3)
```

	OR1	2.5 %	97.5 %
(Intercept)	0.053	0.002	1.618
idade	1.142	1.033	1.263
renda	0.042	0.002	0.726

# Modelos Lineares Generalizados

- Os intervalos de 95% de confiança para os parâmetros do modelo, com base na estatística de Wald.

```
> ICbeta1=confint.default(modelo1, level=0.95); ICbeta1
```

	2.5 %	97.5 %
(Intercept)	-6.35684588	0.4810436
idade	0.03255546	0.2333606
renda	-6.03783801	-0.3201166

- Os intervalos de 95% de confiança para os parâmetros do modelo, com base na estatística de Wald

```
> ICOR1=exp(ICbeta1); ICOR1
```

	2.5 %	97.5 %
(Intercept)	0.001734830	1.6177619
idade	1.033091190	1.2628368
renda	0.002386713	0.7260644

- Razão de chance e intervalo de confiança

```
> round((cbind(OR1, ICOR1)),3)
```

	OR1	2.5 %	97.5 %
(Intercept)	0.053	0.002	1.618
idade	1.142	1.033	1.263
renda	0.042	0.002	0.726



# Modelos Lineares Generalizados

```
> round((cbind(OR1, ICOR1)),3)
              OR1 2.5 % 97.5 %
(Intercept) 0.053 0.002  1.618
idade       1.142 1.033  1.263
renda       0.042 0.002  0.726
```

- **Interpretação das razões de chance (*odds ratio*)**
- Tanto a idade quanto a renda familiar per capita estão significativamente relacionadas com a chance de autoavaliação de saúde não boa (OBS: Note que o p-valor é menor que o nível de significância de 5% e o IC para OR não inclui a unidade).
- A chance do indivíduo reportar um estado de saúde não bom aumenta em 14,2% ao aumentar em 1 ano a idade.

$$(1-1,142) = 0,142$$

- Indivíduos com mais de 3 salários mínimos tem uma chance de reportar um estado de saúde não bom 95,8% menor do que os indivíduos que ganham no máximo 3 salários mínimos.

$$(1-0,042) = 0,958.$$

# Introdução à Regressão Logística

# Regressão com Resposta Binária

- Considere o modelo de regressão tradicional:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + \epsilon_i$$

- Nesse modelo, a variável dependente  $y_i$  geralmente é uma variável contínua (renda per capita, taxa de mortalidade etc.)
- Uma das hipóteses básicas comumente encontrada nos livros de estatística é que variável  $y_i$  possui distribuição normal; essa hipótese não necessita ser verdadeira, para que possamos utilizar os modelos de regressão linear
- Por outro lado, há diversas situações nas quais seria interessante termos um modelo de regressão adaptado, para diferentes tipos de variável resposta
- Uma dessas situações correspondem aos casos nos quais a variável resposta é uma variável binária
- A variável resposta pode corresponder a, por exemplo: cliente pagou ou não pagou o empréstimo, o curso de pós-graduação foi ou não bem sucedido, o imóvel é alugado ou próprio etc.

# Regressão com Resposta Binária

- Na prática, precisamos codificar devidamente as duas alternativas para as variáveis resposta
- A codificação mais comum é através da utilização dos valores 0 e 1; por exemplo, 0 corresponde a imóvel alugado e 1 corresponde a imóvel próprio; 0 corresponde a um curso mal sucedido e 1 corresponde a um curso bem sucedido
- Dessa forma, podemos sempre utilizar um template mais geral, com uma variável resposta  $y_i$  assumindo valores 0 ou 1 (importante ter claramente na nossa mente o que é o valor 0 e o que é o valor 1)
- Portanto, na nossa tabela de dados, precisamos ter uma coluna, com valores estritamente 0 ou 1, dependendo da categoria da variável resposta
- Em geral, os softwares estatísticos estão preparados para trabalhar com outras categorizações, não somente 0 e 1 apenas. O usuário pode indicar qual a categoria corresponde à situação de “sucesso”
- O termo “sucesso” utilizado nesse caso vem da variável aleatória de Bernoulli

# Regressão com Resposta Binária

Situação do Imóvel	Idade do Chefe	Número de Residentes	Renda Familiar (R\$)	Variável Y (Preencher ...)
Alugado	46	3	2200	
Alugado	50	2	1500	
Próprio	28	4	4600	
Alugado	31	4	2823	
Próprio	63	3	4100	
Próprio	53	2	1200	
Alugado	36	2	7800	
Alugado	51	3	3230	
Próprio	42	6	5622	

# Regressão com Resposta Binária

- A variável aleatória de Bernoulli, tradicionalmente vista nos livros de estatística, corresponde a uma variável que assume apenas dois valores, 0 ou 1, sendo que 1 corresponde à situação de “sucesso” e 0 à situação de “insucesso”. Obviamente, esses termos são totalmente ilustrativos
- O importante nessa conceituação é que, atrelado ao evento de sucesso, temos uma probabilidade. Essa probabilidade de sucesso é normalmente representada pela letra  $p$ , e está entre 0 e 1
- Um exemplo muito comum da variável de Bernoulli é a variável aleatória associada a jogarmos uma moeda
- Cara corresponde a “sucesso” e tem probabilidade de  $p = 50\%$  (assumindo que a moeda é não viciada)
- Seja  $X$  então a variável aleatória nesse caso. Sabemos que  $X$  assume valores 0 ou 1 (de acordo com a nossa codificação, sendo que escolhemos arbitrariamente que 1 corresponde a “cara” e 0 a “coroa”)
- Lembrando que o espaço amostral  $S$  corresponde ao conjunto de valores possíveis de uma variável aleatória. Nesse caso,  $S = \{0, 1\}$
- Como podemos modelar então um caso mais geral de jogada de uma moeda  $N$  vezes, e contagem do número de vezes que a moeda resultou “cara”?

# Regressão com Resposta Binária

- A variável aleatória de Bernoulli, tradicionalmente vista nos livros de estatística, corresponde a uma variável que assume apenas dois valores, 0 ou 1, sendo que 1 corresponde à situação de “sucesso” e 0 à situação de “insucesso”. Obviamente, esses termos são totalmente ilustrativos
- O importante nessa conceituação é que, atrelado ao evento de sucesso, temos uma probabilidade. Essa probabilidade de sucesso é normalmente representada pela letra  $p$ , e está entre 0 e 1
- Um exemplo muito comum da variável de Bernoulli é a variável aleatória associada a jogarmos uma moeda
- Cara corresponde a “sucesso” e tem probabilidade de  $p = 50\%$  (assumindo que a moeda é não viciada)
- Seja  $X$  então a variável aleatória nesse caso. Sabemos que  $X$  assume valores 0 ou 1 (de acordo com a nossa codificação, sendo que escolhemos arbitrariamente que 1 corresponde a “cara” e 0 a “coroa”)
- Lembrando que o espaço amostral  $S$  corresponde ao conjunto de valores possíveis de uma variável aleatória. Nesse caso,  $S = \{0, 1\}$
- Como podemos modelar então um caso mais geral de jogada de uma moeda  $N$  vezes, e contagem do número de vezes que a moeda resultou “cara”?

# Regressão com Resposta Binária

- A variável aleatória de Bernoulli, tradicionalmente vista nos livros de estatística, corresponde a uma variável que assume apenas dois valores, 0 ou 1, sendo que 1 corresponde à situação de “sucesso” e 0 à situação de “insucesso”. Obviamente, esses termos são totalmente ilustrativos
- O importante nessa conceituação é que, atrelado ao evento de sucesso, temos uma probabilidade. Essa probabilidade de sucesso é normalmente representada pela letra  $p$ , e está entre 0 e 1
- Um exemplo muito comum da variável de Bernoulli é a variável aleatória associada a jogarmos uma moeda
- Cara corresponde a “sucesso” e tem probabilidade de  $p = 50\%$  (assumindo que a moeda é não viciada)
- Seja  $X$  então a variável aleatória nesse caso. Sabemos que  $X$  assume valores 0 ou 1 (de acordo com a nossa codificação, sendo que escolhemos arbitrariamente que 1 corresponde a “cara” e 0 a “coroa”)
- Lembrando que o espaço amostral  $S$  corresponde ao conjunto de valores possíveis de uma variável aleatória. Nesse caso,  $S = \{0, 1\}$
- Como podemos modelar então um caso mais geral de jogada de uma moeda  $N$  vezes, e contagem do número de vezes que a moeda resultou “cara”?



# Variável Aleatória Binomial

- **Variável aleatória binomial** – trata-se de um “template” muito utilizado, para modelar, por exemplo, o número ocorrência de “sucesso” em  $N$  tentativas. Por exemplo, em um grupo de 100 pacientes, quantos têm algum tipo de câncer. O número de pacientes com câncer entre os 100 no grupo pode ser modelado por uma variável aleatória binomial.
- O espaço amostral de uma variável aleatória binomial é dado por  $S = \{0, 1, 2, 3, 4, \dots, N\}$
- A função de frequência de uma variável aleatória binomial tem expressão:

$$\text{Prob}[X = x] = f(x) = \binom{N}{x} p^x (1 - p)^{N-x}, \quad x = 0, 1, 2, 3, 4, \dots, N$$

- O símbolo  $\binom{N}{x}$  corresponde ao número de combinações possíveis de  $x$  elementos entre os  $N$  totais

$$\binom{N}{x} = \frac{N!}{x! (N - x)!} = \frac{1 \times 2 \times \dots \times (N - 1) \times N}{(1 \times 2 \times \dots \times x) \times (1 \times 2 \times \dots \times (N - x))}$$

- Em geral,  $N$  é conhecido e procura-se estimar o parâmetro  $p$  com base em uma amostra. O parâmetro  $p$  pode ser interpretado como a probabilidade de um indivíduos no grupo ter câncer. Portanto,  $p$  varia entre 0 e 1.
- Quando  $N = 1$ , a variável binomial é chamada variável de Bernoulli, e tem  $S = \{0,1\}$

# O Modelo de Regressão Logística

- Conforme vimos acima, a variável de Bernoulli assume valores 0 ou 1, com probabilidade de sucesso  $\text{Prob}[Y = 1] = p$ , e probabilidade de insucesso  $\text{Prob}[Y = 0] = 1-p$
- Como adaptar então o conceito de variável de Bernoulli ao conceito de regressão?
- Vamos agora tratar então da chamada regressão logística
- Consideremos então uma base de dados de unidades observacionais (indivíduos, domicílios, municípios, países, cursos de pós-graduação etc.)
- Para cada unidade observacional, temos uma variável  $y_i$  assumindo valores 0 ou 1, e temos um conjunto de colunas que podem ser usadas para construirmos variáveis explicativas  $x_{1,i}, x_{2,i}, \dots, x_{k,i}$
- A ideia básica da regressão logística é assumir que cada valor individual  $y_i$  corresponde a uma variável aleatória de Bernoulli, com probabilidade de sucesso (por exemplo, indivíduo ter câncer – paradoxalmente!) dada por  $\text{Prob}[y_i = 1] = p_i$
- O “pulo do gato” é fazer com que  **$\text{Prob}[y_i = 1] = p_i$  dependa das variáveis explicativas  $x_{1,i}, x_{2,i}, \dots, x_{k,i}$**

# O Modelo de Regressão Logística

- O “pulo do gato” é fazer com que  $\text{Prob}[y_i = 1] = p_i$  dependa das variáveis explicativas  $x_{1,i}, x_{2,i}, \dots, x_{k,i}$

- Uma possível alternativa é assumir

$$\text{Prob}[y_i = 1] = p_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}$$

- O problema da alternativa acima é que  $\text{Prob}[y_i = 1] = p_i$  tem que estar estritamente no intervalo  $[0, 1]$
- O termo  $\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}$ , por outro lado, pode assumir valores menores do que 0 ou maiores do que 1
- Modelo de regressão logística:


$$\text{Prob}[y_i = 1] = p_i = \frac{e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}}{1 + e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}}$$

- A fórmula acima implica que as probabilidades  $p_i$  vão se situar o intervalo  $(0,1)$ , como desejado
- Pode-se mostrar que, quando  $\beta_1$  é positivo, quando  $x_{1i}$  aumenta, a probabilidade de “sucesso” também aumenta

# O Modelo de Regressão Logística

- Considere um modelo simplificado de regressão logística, no qual temos a probabilidade de sucesso dada por

$$\text{Prob}[y_i = 1] = p_i = \frac{e^{\alpha + \beta x_{1i}}}{1 + e^{\alpha + \beta x_{1i}}}, \text{ com } \beta > 0$$



# Regressão Logística no R

```
dados3$alta_mort_infantil <- ifelse(dados3$mort_infantil > 24, 1, 0)
```

```
#-----  
#---- rodando uma regressão logística  
#-----
```

```
mod1 <- glm(formula = alta_mort_infantil ~ renda_per_capita,  
            family = binomial(link = "logit"), data = dados3)  
summary(mod1)
```

```
mod2 <- glm(formula = alta_mort_infantil ~ indice_gini,  
            family = binomial(link = "logit"), data = dados3)  
summary(mod2)
```

```
mod3 <- glm(formula = alta_mort_infantil ~ perc_crianças_extrem_pobres,  
            family = binomial(link = "logit"), data = dados3)  
summary(mod3)
```

```
mod4 <- glm(formula = alta_mort_infantil ~ perc_pessoas_dom_agua_estogo_inadequados,  
            family = binomial(link = "logit"), data = dados3)  
summary(mod4)
```

# Regressão Logística no R

```
> summary(mod1)
```

Call:

```
glm(formula = alta_mort_infantil ~ renda_per_capita, family = binomial(link = "logit"),  
     data = dados3)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.4659	-0.2831	-0.0536	-0.0003	3.1928

Coefficients:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	5.2070406	0.1834282	28.39	<2e-16 ***
renda_per_capita	-0.0182626	0.0006154	-29.68	<2e-16 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 6163.7 on 5563 degrees of freedom  
Residual deviance: 3042.4 on 5562 degrees of freedom  
AIC: 3046.4

Number of Fisher Scoring iterations: 7

# Regressão Logística no R

```
> summary(mod4)
```

Call:

```
glm(formula = alta_mort_infantil ~ perc_pessoas_dom_agua_estogo_inadequados,  
     family = binomial(link = "logit"), data = dados3)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-3.4654	-0.5446	-0.4690	-0.4570	2.1500

Coefficients:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	-2.206750	0.051311	-43.01	<2e-16 ***
perc_pessoas_dom_agua_estogo_inadequados	0.096166	0.003172	30.32	<2e-16 ***

---

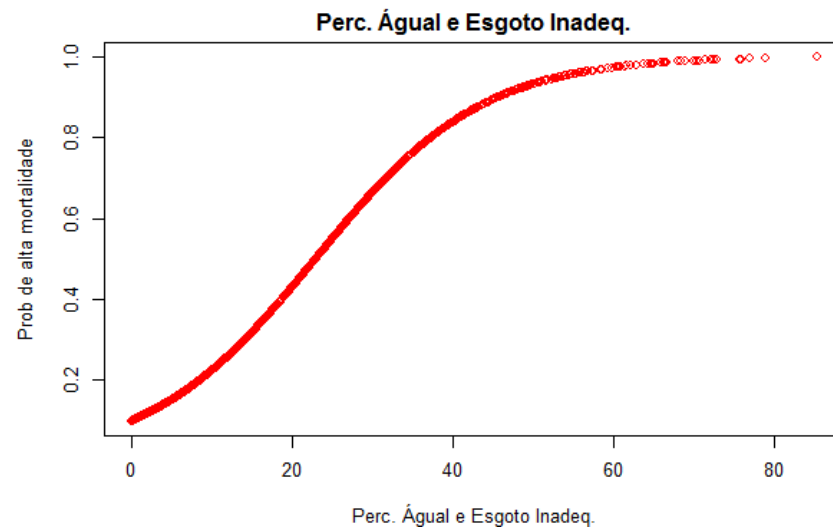



Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 6163.7 on 5563 degrees of freedom  
Residual deviance: 4819.0 on 5562 degrees of freedom  
AIC: 4823

Number of Fisher Scoring iterations: 4

# Regressão Logística no R





# Método de Máxima Verossimilhança

- Da mesma forma que no caso da regressão linear, com base em uma amostra de observações, queremos estimar os parâmetros desconhecidos  $\beta_0, \beta_1, \beta_2, \dots, \beta_k$
- O método comumente utilizado nesse caso é o método de “máxima verossimilhança”
- Para cada observação  $i$ , a probabilidade que observaremos  $y_i=1$  é igual a  $p_i$ , enquanto a probabilidade de observarmos  $y_i=0$  é igual a  $(1-p_i)$
- De maneira compacta, podemos dizer que a probabilidade de observar o valor  $y_i$  (0 ou 1) é igual a

$$\text{Prob}[y_i] = p_i^{y_i} \times (1 - p_i)^{1-y_i}$$

- De fato, se  $y_i=1$ ,  $\text{Prob}[y_i = 1] = p_i^1 \times (1 - p_i)^{1-1} = p_i$
- De fato, se  $y_i=0$ ,  $\text{Prob}[y_i = 0] = p_i^0 \times (1 - p_i)^{1-0} = (1 - p_i)$
- A probabilidade de observar toda amostra é dada pelo produto das probabilidades individuais (assumindo que as observações são independentes)

$$\text{Prob}[y_1, \dots, y_n] = \prod_{i=1}^n p_i^{y_i} \times (1 - p_i)^{1-y_i}$$

# Método de Máxima Verossimilhança

- A função de verossimilhança é justamente a probabilidade de observar o que de fato encontramos na amostra, ou seja  $\text{Prob}[y_1, \dots, y_n] = \prod_{i=1}^n p_i^{y_i} \times (1 - p_i)^{1-y_i}$
- Considere então um vetor qualquer de parâmetros  $\beta_0, \beta_1, \dots, \beta_k$
- A função de verossimilhança, assumindo que os valores  $y_i$  são variáveis de Bernoulli, independentes, é escrita como

$$\begin{aligned} L(\beta_0, \beta_1, \dots, \beta_k) &= \prod_{i=1}^n p_i^{y_i} \times (1 - p_i)^{1-y_i} \\ &= \prod_{i=1}^n \left[ \frac{e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}}{1 + e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}} \right]^{y_i} \times \left[ \frac{1}{1 + e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}} \right]^{1-y_i} \end{aligned}$$

- O método de máxima verossimilhança é comumente empregado para estimar os parâmetros do modelos de regressão de forma geral
- O método consistem em encontrar os valores dos parâmetros  $\beta_0, \beta_1, \beta_2, \dots, \beta_k$  para os quais a função  $L(\beta_0, \beta_1, \dots, \beta_k)$  atinge um valor máximo
- Note que os valores de  $x_{1,i}, x_{2,i}, \dots, x_{k,i}$  e  $y_i$  são conhecidos, dado que estamos usando uma amostra disponível

# Método de Máxima Verossimilhança

- Conforme vimos anteriores, por motivos numéricos e analíticos, trabalhamos com o log da função de verossimilhança, ao invés da função original

$$\log L(\beta_0, \beta_1, \dots, \beta_k) = \sum_{i=1}^n y_i \log p_i + (1 - y_i) \log(1 - p_i)$$

$$\begin{aligned} & \log L(\beta_0, \beta_1, \dots, \beta_k) \\ &= \sum_{i=1}^n y_i [\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}] - \sum_{i=1}^n \log[1 + e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}] \end{aligned}$$

- Obtemos então os estimadores de máxima verossimilhança para os parâmetros  $\beta_0, \beta_1, \beta_2, \dots, \beta_k$  encontrando o máximo da função de log-verossimilhança  $\log L(\beta_0, \beta_1, \dots, \beta_k)$
- Uma das formas de se encontrar os máximos de uma função é encontrar as derivadas e igualar as derivadas a zero
- Para o caso da estimação de máxima verossimilhança no caso de regressão linear, a técnica de achar as derivadas e igualar as derivadas a zero implica na fórmula fechada do estimador de mínimos quadrados ordinários
- Para regressão linear, o estimador de máxima verossimilhança é numericamente igual ao estimador de mínimos quadrados ordinários

# Método de Máxima Verossimilhança

- No caso de regressão logística, não é possível encontrar uma fórmula fechada para o estimador dos parâmetros  $\beta_0, \beta_1, \beta_2, \dots, \beta_k$
- Por isso, o R (e outros programas estatísticos) têm que efetuar uma maximização iterativa numérica, quando têm que estimar os parâmetros via máxima verossimilhança
- Considere um modelo simplificado de regressão logística, no qual temos a probabilidade de sucesso dada por

$$\text{Prob}[y_i = 1] = p_i = \frac{e^{\alpha + \beta x_{1i}}}{1 + e^{\alpha + \beta x_{1i}}}$$

- Nesse caso, temos dois parâmetros desconhecidos  $\alpha$  e  $\beta$
- A função de log verossimilhança tem expressão

$$\log L(\alpha, \beta) = \sum_{i=1}^n y_i [\alpha + \beta x_{1i}] - \sum_{i=1}^n \log[1 + e^{\alpha + \beta x_{1i}}]$$

- Maximizando  $\log L(\alpha, \beta)$ , encontramos os estimadores  $\hat{\alpha}$  e  $\hat{\beta}$  para os parâmetros  $\alpha$  e  $\beta$

# Regressão Logística no R

```
> summary(mod1)
```

Call:

```
glm(formula = alta_mort_infantil ~ renda_per_capita, family = binomial(link = "logit"),  
     data = dados3)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.4659	-0.2831	-0.0536	-0.0003	3.1928

Coefficients:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	5.2070406	0.1834282	28.39	<2e-16 ***
renda_per_capita	-0.0182626	0.0006154	-29.68	<2e-16 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 6163.7 on 5563 degrees of freedom  
Residual deviance: 3042.4 on 5562 degrees of freedom  
AIC: 3046.4

Number of Fisher Scoring iterations: 7

# Regressão Logística no R

```
> summary(mod1)
```

Call:

```
glm(formula = alta_mort_infantil ~ renda_per_capita, family = binomial(link = "logit"),  
     data = dados3)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.4659	-0.2831	-0.0536	-0.0003	3.1928

Coefficients:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	5.2070405	0.1834282	28.39	<2e-16 ***
renda_per_capita	-0.0182625	0.0006154	-29.68	<2e-16 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 6163.7 on 5563 degrees of freedom  
Residual deviance: 3042.4 on 5562 degrees of freedom  
AIC: 3046.4

Number of Fisher Scoring iterations: 7

# Teste da Razão de Verossimilhança

- Para testar vários parâmetros ao mesmo tempo, o teste mais comumente empregado é o teste da razão de verossimilhança, ou likelihood ratio test (LRT)
- Vamos supor que queremos testar a hipótese nula conjunta:

$$H_0: \beta_2 = \beta_5 = 0$$

$$H_A: \beta_2 \neq 0 \text{ ou } \beta_5 \neq 0$$

- O teste de razão verossimilhança tem como estatística teste simplesmente a diferença

$$LRT = 2 \times [\log L(\beta) - \log L(\beta | \beta_2 = \beta_5 = 0)]$$

- $\log L(\beta)$  é o log-verossimilhança (no máximo) para o modelo sem restrição
- $\log L(\beta | \beta_2 = \beta_5 = 0)$  é o log-verossimilhança (no máximo), para o modelo com restrição, dada pela hipótese nula. Nesse caso, a restrição corresponde a simplesmente excluirmos as variáveis  $x_2$  e  $x_5$  da regressão
- Qual a distribuição aproximada para essa estatística teste, assumindo que a hipótese nula é verdadeira (ou seja,  $\beta_2 = \beta_5 = 0$ )

# Teste da Razão de Verossimilhança

- Intrinsecamente relacionado à estatística de log-likelihood está a estatística *Deviance*
- Essa estatística é dada pelo output da regressão, e tem expressão

$$Deviance = -2 \times \log L(\beta)$$

- Portanto,

$$LRT = 2 \times [\log L(\beta) - \log L(\beta | \beta_2 = \beta_5 = 0)]$$

$$= - [\text{Deviance}_{\text{irrest}} - \text{Deviance}_{\text{rest}}]$$

- Com  $\text{Deviance}_{\text{irrest}}$  e  $\text{Deviance}_{\text{rest}}$  correspondendo aos modelos irrestrito e restrito
- Quando a hipótese nula é verdadeira, ou seja,  $\beta_2 = \beta_5 = 0$ , a estatística teste LRT tem distribuição qui-quadrada, com número de graus de liberdade igual ao número de restrições no modelo
- Para duas restrições, o valor crítico da estatística teste é dado por `valor_critico_5pc <- qchisq(0.95, 2) = 5.991465`, para 5% de probabilidade de erro do tipo I



# R<sup>2</sup> para Regressão Logística

- Em regressão linear, uma medida comumente utilizada para verificar o ajuste do modelo é o coeficiente de determinação
- No caso de regressão logística, há várias alternativas para o equivalente ao R<sup>2</sup> da regressão linear
- McFadden's R<sup>2</sup>:  $R^2_{McF} = 1 - \ln(L_M) / \ln(L_0)$ , onde  $\ln(L_0)$  é função de log-verossimilhança, para um modelo com apenas o intercepto
- Nagelkerke / Cragg & Uhler's:

$$R^2_{C\&U} = \frac{1 - \left[ \frac{L_0}{L_M} \right]^{\frac{2}{n}}}{1 - L_0^{2/n}}, \text{ com } 0 \leq R^2_{C\&U} \leq 1$$

- Cox & Snell (maximum likelihood):

$$R^2_{C\&S} = 1 - \left[ \frac{L_0}{L_M} \right]^{\frac{2}{n}}$$

- No caso de Cox & Snell, o valor máximo não é 1. A interpretação dos pseudo-R<sup>2</sup> não são tão simples quando do R<sup>2</sup> no caso linear

# Seleção de Variáveis

- Da mesma maneira que no caso de regressão linear, podemos usar os indicadores AIC e BIC para seleção de modelos
- Dentre vários modelos, podemos selecionar aquele (ou aqueles) com menor AIC ou BIC
- Critério de Informação de Akaike - AIC

$$AIC = -2 \log L(\beta_0, \beta_1, \dots, \beta_k) + 2 \times p$$

O número  $p$  corresponde ao número de parâmetros livres na regressão. No caso da regressão logística, temos: um intercepto e  $k$  variáveis preditoras

$$p = 1 + k = 1 + k$$

- Critério de Informação Bayesiano - BIC

$$BIC = -2 \log L(\beta_0, \beta_1, \dots, \beta_k) + \log n \times p$$

- Os termos  $[2 \times p]$  e  $[\log n \times p]$ , no AIC e BIC, correspondem a pênaltis para a inclusão adicional de variáveis
- Portanto, a inclusão de variáveis vai aumentar  $\log L(\beta_0, \beta_1, \dots, \beta_k)$ , mas aumenta também os pênaltis  $[2 \times p]$  e  $[\log n \times p]$
- Como de costume, o BIC tende a selecionar modelos mais parcimoniosos

# Regressão Logística no R

```
> summary(mod1)
```

Call:

```
glm(formula = alta_mort_infantil ~ renda_per_capita, family = binomial(link = "logit"),  
     data = dados3)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.4659	-0.2831	-0.0536	-0.0003	3.1928

Coefficients:

	Estimate	Std. Error	z value	Pr(> z )
(Intercept)	5.2070406	0.1834282	28.39	<2e-16 ***
renda_per_capita	-0.0182626	0.0006154	-29.68	<2e-16 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 6163.7 on 5563 degrees of freedom

Residual deviance: 3042.4 on 5562 degrees of freedom

AIC: 3046.4

Number of Fisher Scoring iterations: 7

# Interpretação dos Coeficientes da Reg Logística

- O método de máxima verossimilhança nos dá os coeficientes estimados para o modelo de regressão logística
- No entanto, precisamos entender qual o significado desses coeficientes. Como interpretá-los? Sabemos interpretar os sinais dos coeficientes, e precisamos agora entender a magnitude
- *Odds ratio* ou “razão de chances”: o Palmeiras tem chance de 3 contra 1 de vencer o campeonato paulista. Nesse caso, a probabilidade do o Palmeira ganhar é de  $3/(3+1) = 75\%$
- Por outro lado, dado que o Palmeiras tem 75% de chance de vencer, a razão de chances é  $0.75/0.25 = 3$  contra 1
- Para a regressão logística, a razão de chances de sucesso versus insucesso (1 versus 0) é dada pela razão das probabilidades

$$\frac{p_i}{1 - p_i} = \frac{\frac{e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}}{1 + e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}}}{1 - \left[ \frac{e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}}{1 + e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}} \right]} = \frac{\frac{e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}}{1 + e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}}}{\frac{1}{1 + e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}}}$$

$$\frac{p_i}{1 - p_i} = e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}$$

# Interpretação dos Coeficientes da Reg Logística

- As razões de chance (*odds ratio*) são dadas por  $or = p / (1-p)$ , onde  $p$  = probabilidade de sucesso e  $(1-p)$  é a probabilidade de fracasso.
- Uma razão de chances de 1 indica que a condição ou evento sob estudo é igualmente provável de ocorrer nos dois grupos. Uma razão de chances maior do que 1 indica que a condição ou evento tem maior probabilidade de ocorrer no primeiro grupo. Finalmente, uma razão de chances menor do que 1 indica que a probabilidade é menor no primeiro grupo do que no segundo.

# Interpretação dos Coeficientes da Reg Logística

- Portanto, para uma regressão logística, a razão de chances para a observação  $i$  é dada por

$$r_i = \frac{p_i}{1 - p_i} = e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}$$

- Imagine agora que a variável  $x_{1i}$  teve um incremento de uma unidade. A nova razão de chances vai ser

$$r_i^* = e^{\beta_0 + \beta_1 [1 + x_{1i}] + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}$$

$$r_i^* = e^{\beta_1} e^{\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki}}$$

$$r_i^* = e^{\beta_1} r_i$$

- Portanto,  $e^{\beta_1}$  indica o aumento (ou redução) da razão de chances quando aumentamos em uma unidade a variável  $x_{1i}$
- Se  $x_{1i}$  for uma variável dummy indicando se o paciente teve um tratamento ou não, o termo  $e^{\beta_1}$  indica o quanto a razão de chances se altera quando o paciente passa pelo tratamento (versus quando ele não passa)
- A maioria dos softwares estatísticos reporta os termos  $e^{\beta_1}$  para todos os coeficientes no modelo. É possível também extrair intervalos de confiança para  $e^{\beta_1}$

# Interpretação dos Coeficientes da Reg Logística

- O código abaixo calcula os valores para  $e^{\beta_1}$ , com os respectivos intervalos de confiança, com 95% de probabilidade de cobertura

#---- odds-ratio, com intervalos de confiança de 95%

```
mod5.reduzido <- glm(formula = alta_mort_infantil ~ renda_per_capita
+ indice_gini
+ salario_medio_mensal
+ perc_crianças_extrem_pobres
+ perc_crianças_pobres
+ perc_pessoas_dom_agua_estogo_inadequados
+ perc_pessoas_dom_paredes_inadequadas
+ perc_pop_dom_com_coleta_lixo
+ perc_pop_rural
+ as.factor(Regiao),
family = binomial(link = "logit"), data = dados3)
summary(mod5.reduzido)

data.frame(exp(coef(mod5.reduzido)), exp(confint(mod5.reduzido)))

odds.ratio(mod5.reduzido) #--- pacote "questionr"
```

# Modelos de Regressão

- **4ª Lista de exercícios para entregar em 04/12/2018.**

- Os exercícios podem ser entregues em grupos de 2 alunos, e o grupo deve submeter o código em R utilizado para responder ao exercício, juntamente com a discussão dos resultados.
- Utilize a base de dados do IDH brasil 2010 (IDH\_Brasil\_2010.csv)
- Rode a regressão logística abaixo:

```
mod5.reduzido <- glm(formula = alta_mort_infantil ~ renda_per_capita  
  + indice_gini  
  + salario_medio_mensal  
  + perc_crianças_extrem_pobres  
  + perc_crianças_pobres  
  + perc_pessoas_dom_agua_estogo_inadequados  
  + perc_pessoas_dom_paredes_inadequadas  
  + perc_pop_dom_com_coleta_lixo  
  + perc_pop_rural  
  + as.factor(Regiao),  
  family = binomial(link = "logit"), data = dados3)  
summary(mod5.reduzido)
```

- Questão 1: Interprete os coeficientes da regressão que apresentem significância estatística;



# Modelos de Regressão Logística

- (continuação):

- Questão 2: Refaça a questão 1, considerando o modelo de regressão logística abaixo, interprete os odds-ratio dos coeficientes que apresentem significância estatística.

```
mod5.reduzido <- glm(formula = alta_mort_infantil ~ renda_per_capita
+ indice_gini
+ salario_medio_mensal
+ perc_crianças_extrem_pobres
+ perc_crianças_pobres
+ perc_pessoas_dom_agua_estogo_inadequados
+ perc_pessoas_dom_paredes_inadequadas
+ perc_pop_dom_com_coleta lixo
+ perc_pop_rural
+ as.factor(Regiao)
+ as.factor(Regiao)*renda_per_capita,
family = binomial(link = "logit"), data = dados3)
summary(mod5.reduzido)
```

Questão 3: Com base nos critérios AIC e BIC qual desses modelos seriam selecionados?

Obrigado!